

Team Bundestag

Natural Language Processing



Datenbeschaffung

Datengrundlage

Plenarprotokolle
seit 1949

Ständige
Formatwechsel



Beschränkung auf Daten
ab 1991

PLAINTEXT!

Was steht im Protokolltext?



Redebeiträge



Applaus




Zwischenrufe

Statistische Analyse




Statistische Analyse




Wer ruft wie oft hinein?

Anzahl der Zwischenrufe nach Partei

*Daten der aktuellen Bundestagsperiode




Wie oft rufen einzelne Abgeordnete hinein?




Wer ruft wem rein?

*Daten der aktuellen Bundestagsperiode



Wer ruft wem rein?

*Normalisiert nach Anzahl der Sätze der Redner-Partei sowie
Sitzen der Zwischenruf-Partei



Mehr Plots? Selbst ausprobieren!



https://huggingface.co/spaces/stellamo/bundestag_stats

Sentiment Analyse Zwischenrufe

Selbst labeln. Aber wie?

“Es war so eine schöne Rede!”


“Das ist doch positiv!”

“Vier Tage Anhörung!”



Positiv?
Negativ?
Neutral?

Sind alle Zwischenrufe negativ?



*4500 gelabelte Zwischenrufe.
Zufällige Auswahl [1991,2024]

Klassifikation


BERT Sentiment

Pretrained


- 56% Accuracy
- Verwechslung
Negativ <-> Neutral

Finetuning

- 77% Accuracy
- Durchwegs bessere
F1-Scores
- Falschklassifikation
Negativ -> Neutral



Mein Task?



1. Naive Bayes

Genauigkeit: 92.50%

Klassifikationsbericht:

	precision	recall	f1-score	support
0	0.93	0.99	0.96	5831
1	0.02	0.00	0.00	411
accuracy			0.93	6242
macro avg	0.48	0.50	0.48	6242
weighted avg	0.87	0.93	0.90	6242

Verteilung der Labels:

label	
0	29156
1	2053

2. BERT (Satzebene)

3. BERT (Tokenebene)



Google
BERT

2. BERT (Satzebene)

Input

texts = [

"Sehr geehrter Herr Präsident! Liebe Kolleginnen und Kollegen! Das Coronavirus hat uns mit voller Wucht getroffen. Das Ausmaß der Pandemie – wir erleben das auch heute angesichts neuer Infektionszahlen – ist historisch. Es ist allerdings eine Krise, die die gesamte Welt erfasst hat, und in vielen Ländern ist aus dieser Gesundheitskrise längst mehr geworden, nämlich eine dramatische soziale Krise mit Massenarbeitslosigkeit, mit Hunger, mit Obdachlosigkeit, und das auch in entwickelten Industriestaaten. In den USA beispielsweise lag die Arbeitslosigkeit in diesem Jahr streckenweise bei über 14 Prozent. Vor den Food Banks, den amerikanischen Suppenküchen, bildeten sich teilweise kilometerlange Autoschlangen – auf der Suche nach Lebensmitteln. Übrigens, auch das ist ein Grund, warum es gut ist, dass – hoffentlich – jetzt ein amerikanischer Präsident ins Weiße Haus einzieht, der ein soziales Gespür hat."

"(Beifall bei der SPD und der CDU/CSU sowie des Abg. Johannes Vogel [Olpe] [FDP])",

"Meine Damen und Herren, auch bei uns hat die Pandemie unsere Wirtschaft schwer erschüttert. Trotz dieser massiven wirtschaftlichen Erschütterung ist in Deutschland aus dieser Pandemie kein soziales Erdbeben geworden."

"(Zuruf von der AfD): Noch nicht!)"

]



Output

Predicted Einwurf Indices: [3, 5, 6, 11, 13, 15, 17, 19, 25, 27, 31, 33, 37, 39]

Satz 0: Sehr geehrter Herr Präsident! Liebe Kolleginnen und Kollegen! Das Coronavirus hat uns mit voller Wucht getroffen.

Das Ausmaß der Pandemie – wir erleben das auch heute angesichts neuer Infektionszahlen – ist historisch.

Es ist allerdings eine Krise, die die gesamte Welt erfasst hat, und in vielen Ländern ist aus dieser Gesundheitskrise längst mehr geworden, nämlich eine dramatische soziale Krise mit Massenarbeitslosigkeit, mit Hunger, mit Obdachlosigkeit, und das auch in entwickelten Industriestaaten. In den USA beispielsweise lag die Arbeitslosigkeit in diesem Jahr streckenweise bei über 14 Prozent. Vor den Food Banks, den amerikanischen Suppenküchen, bildeten sich teilweise kilometerlange Autoschlangen – auf der Suche nach Lebensmitteln. Übrigens, auch das ist ein Grund, warum es gut ist, dass – hoffentlich – jetzt ein amerikanischer Präsident ins Weiße Haus einzieht, der ein soziales Gespür hat. ->

Vorhergesagt: **Kein Einwurf**

Satz 1: (Beifall bei der SPD und der CDU/CSU sowie des Abg. Johannes Vogel [Olpe] [FDP]) -> Vorhergesagt: **Kein Einwurf**

Satz 2: Meine Damen und Herren, auch bei uns hat die Pandemie unsere Wirtschaft schwer erschüttert. Trotz dieser massiven wirtschaftlichen Erschütterung ist in Deutschland aus dieser Pandemie kein soziales Erdbeben geworden. -> Vorhergesagt: **Kein Einwurf**

Satz 3: (Zuruf von der AfD): Noch nicht!) -> Vorhergesagt: **Einwurf**

2. BERT (Satzebene)

BERT Model Accuracy: 0.98

```
[[3142  40]  
[  63 2119]]
```

	precision	recall	f1-score	support
Kein Einwurf	0.98	0.99	0.98	3182
Einwurf	0.98	0.97	0.98	2182
accuracy			0.98	5364
macro avg	0.98	0.98	0.98	5364
weighted avg	0.98	0.98	0.98	5364

3. BERT (Tokenenebene)

- Cross-Entropy-Loss

Input

test_texts = ["Sehr geehrte Damen und Herren, heute möchte ich über ein wichtiges Thema sprechen. Entschuldigung, darf ich kurz unterbrechen? <interruption> Es geht um die aktuellen wirtschaftlichen Entwicklungen. Die Zahlen zeigen einen positiven Trend, aber wir müssen vorsichtig sein. Ich habe eine Frage zu den genauen Daten, die Sie erwähnt haben. Wir dürfen nicht vergessen, dass viele Menschen noch immer von der Krise betroffen sind. Es ist entscheidend, dass wir weiterhin Maßnahmen zur Unterstützung anbieten. Vielen Dank für Ihre Aufmerksamkeit."]



Output

Sentence: [CLS]: 0 se: 0 ##hr: 0 gee: 0 ##hr: 0 ##te: 0 dame: 0 ##n: 0 und: 0 herr: 0 ##en: 0 ,: 0 he: 0 ##ute: 0 mo: 0 ##cht: 0 ##e: 0 ich: 0 uber: 0 ein: 0 wi: 0 ##cht: 0 ##ige: 0 ##s: 0 them: 0 ##a: 0 sp: 0 ##re: 0 ##chen: 0 .: 0 en: 0 ##ts: 0 ##chu: 0 ##ld: 0 ##ig: 0 ##ung: 0 ,: 0 dar: 0 ##f: 0 ich: 0 ku: 0 ##rz: 0 un: 0 ##ter: 0 ##bre: 0 ##chen: 0 ?: 0 <: 0 interruption: 0 >: 0 es: 0 ge: 0 ##ht: 0 um: 0 die: 0 ak: 0 ##tu: 0 ##elle: 0 ##n: 0 wi: 0 ##rts: 0 ##chaft: 0 ##liche: 0 ##n: 0 en: 0 ##t: 0 ##wick: 0 ##lun: 0 ##gen: 0 .: 0 die: 0 za: 0 ##hl: 0 ##en: 0 ze: 0 ##igen: 0 eine: 0 ##n: 0 positive: 0 ##n: 0 trend: 0 ,: 0 abe: 0 ##r: 0 wi: 0 ##r: 0 mu: 0 ##ssen: 0 vo: 0 ##rs: 0 ##ich: 0 ##ti: 0 ##g: 0 se: 0 ##in: 0 .: 0 ich: 0 ha: 0 ##be: 0 eine: 0 fra: 0 ##ge: 0 zu: 0 den: 0 gen: 0 ##au: 0 ##en: 0 date: 0 ##n: 0 ,: 0 die: 0 si: 0 ##e: 0 er: 0 ##wa: 0 ##hn: 0 ##t: 0 ha: 0 ##ben: 0 .: 0 wi: 0 ##r: 0 du: 0 ##rf: 0 ##en: 0 nic: 0 ##ht: 0 verge: 0 ##ssen: 0 ,: 0 das: 0 ##s: 0 vie: 0 ##le: 0 men: 0 ##schen: 0 no: 0 ##ch: 0 im: 0 ##mer: 0 von: 0 der: 0 kris: 0 ##e: 0 bet: 0 ##ro: 0 ##ffen: 0 sin: 0 ##d: 0 .: 0 es: 0 ist: 0 en: 0 ##ts: 0 ##che: 0 ##ide: 0 ##nd: 0 ,: 0 das: 0 ##s: 0 wi: 0 ##r: 0 wei: 0 ##ter: 0 ##hin: 0 ma: 0 ##ß: 0 ##nah: 0 ##men: 0 zur: 0 un: 0 ##ters: 0 ##tu: 0 ##tz: 0 ##ung: 0 an: 0 ##bie: 0 ##ten: 0 .: 0 vie: 0 ##len: 0 dan: 0 ##k: 0 fur: 0 i: 0 ##hre: 0 auf: 0 ##mer: 0 ##ks: 0 ##am: 0 ##kei: 0 ##t: 0 .: 0 [SEP]: 0

3. BERT (Tokenenebene)

- weighted Cross-Entropy-Loss

Input

test_texts = ["Sehr geehrte Damen und Herren, heute möchte ich über ein wichtiges Thema sprechen. Entschuldigung, darf ich kurz unterbrechen? <interruption> Es geht um die aktuellen wirtschaftlichen Entwicklungen. Die Zahlen zeigen einen positiven Trend, aber wir müssen vorsichtig sein. Ich habe eine Frage zu den genauen Daten, die Sie erwähnt haben. Wir dürfen nicht vergessen, dass viele Menschen noch immer von der Krise betroffen sind. Es ist entscheidend, dass wir weiterhin Maßnahmen zur Unterstützung anbieten. Vielen Dank für Ihre Aufmerksamkeit."]



Output

Sentence: [CLS]: 0 se: 0 ##hr: 0 gee: 0 ##hr: 0 ##te: 0 dame: 0 ##n: 0 und: 0 herr: 0 ##en: 0 ,: 0 he: 0 ##ute: 0 mo: 0 ##cht: 0 ##e: 0 ich: 0 uber: 0 ein: 0 wi: 0 ##cht: 0 ##ige: 0 ##s: 0 them: 0 ##a: 0 sp: 0 ##re: 0 ##chen: 0 .: 0 en: 0 ##ts: 0 ##chu: 0 ##ld: 0 ##ig: 0 ##ung: 0 ,: 0 dar: 0 ##f: 0 ich: 0 ku: 0 ##rz: 0 un: 0 ##ter: 0 ##bre: 0 ##chen: 0 ?: 0 <: 0 interruption: 0 >: 0 es: 0 ge: 0 ##ht: 0 um: 0 die: 0 ak: 0 ##tu: 0 ##elle: 0 ##n: 0 wi: 0 ##rts: 0 ##chaft: 0 ##liche: 0 ##n: 0 en: 0 ##t: 0 ##wick: 0 ##lun: 0 ##gen: 0 .: 0 die: 0 za: 0 ##hl: 0 ##en: 0 ze: 0 ##igen: 0 eine: 0 ##n: 0 positive: 0 ##n: 0 trend: 0 ,: 0 abe: 0 ##r: 0 wi: 0 ##r: 0 mu: 0 ##ssen: 0 vo: 0 ##rs: 0 ##ich: 0 ##ti: 0 ##g: 0 se: 0 ##in: 0 .: 0 ich: 0 ha: 0 ##be: 0 eine: 0 fra: 0 ##ge: 0 zu: 0 den: 0 gen: 0 ##au: 0 ##en: 0 date: 0 ##n: 0 ,: 0 die: 0 si: 0 ##e: 0 er: 0 ##wa: 0 ##hn: 0 ##t: 0 ha: 0 ##ben: 0 .: 0 wi: 0 ##r: 0 du: 0 ##rf: 0 ##en: 0 nic: 0 ##ht: 0 verge: 0 ##ssen: 0 ,: 0 das: 0 ##s: 0 vie: 0 ##le: 0 men: 0 ##schen: 0 no: 0 ##ch: 0 im: 0 ##mer: 0 von: 0 der: 0 kris: 0 ##e: 0 bet: 0 ##ro: 0 ##ffen: 0 sin: 0 ##d: 0 .: 0 es: 0 ist: 0 en: 0 ##ts: 0 ##che: 0 ##ide: 0 ##nd: 0 ,: 0 das: 0 ##s: 0 wi: 0 ##r: 0 wei: 0 ##ter: 0 ##hin: 0 ma: 0 ##ß: 0 ##nah: 0 ##men: 0 zur: 0 un: 0 ##ters: 0 ##tu: 0 ##tz: 0 ##ung: 0 an: 0 ##bie: 0 ##ten: 0 .: 0 vie: 0 ##len: 0 dan: 0 ##k: 0 fur: 0 i: 0 ##hre: 0 auf: 0 ##mer: 0 ##ks: 0 ##am: 0 ##kei: 0 ##t: 0 .: 0 [SEP]: 0

ohm

4. RoBERTa



5. LLM-Modell (GPT 3.5 Turbo)

New chat

Willkommen zur
Präsentation!

BundestagGPT

Hallo vom BundestagGPT!

Willkommen zur Präsentation!

